

TPU (Tensor Processing Unit)

1 Introducción a la Unidad de Procesamiento Tensorial (TPU)

Una **TPU** (*Tensor Processing Unit*) es un circuito integrado de aplicación específica (ASIC) desarrollado por Google.

Su propósito principal es acelerar las cargas de trabajo de redes neuronales artificiales y operaciones de álgebra lineal, para lograr esto no realiza ciclos de lectura y escritura de registros y memoria caché como lo hacen las CPU y GPU tradicionales, sino que implementa una arquitectura de matriz sistólica optimizada para multiplicación y acumulación de matrices (MAC).

Una matriz sistólica es una arquitectura con múltiples celdas idénticas conectadas con sus vecinos inmediatos, donde cada celda realiza operaciones aritméticas simples y pasa los resultados a la siguiente celda. Permite aprovechar el paralelismo, reduciendo tiempos, también reduce la latencia ya que las matrices se comunican con sus vecinos más cercanos y mueve los datos desde la memoria principal consumiendo menos energía.

En este paradigma, los datos fluyen a través de una red bidimensional de unidades aritmético-lógicas (ALUs) interconectadas.

$$\mathbf{C} = \mathbf{A} \times \mathbf{B} + \mathbf{D} \quad (1)$$

Donde **A** y **B** son matrices de activaciones y pesos, respectivamente.

2 Análisis Comparativo de Arquitecturas

Las TPU comparten similitudes y diferencias con las Unidades Centrales de Procesamiento (CPU) y las Unidades de Procesamiento Gráfico (GPU).

2.1 CPU (Central Processing Unit)

La CPU es un procesador de propósito general basado en la arquitectura tradicional de Von Neumann. Está optimizada para minimizar la *latencia de ejecución* de hilos secuenciales complejos.

- **Cálculo Escalar:** Procesa elementos de datos individuales de forma secuencial:

$$y_i = f(x_i) \quad (2)$$

- **Componentes:** Posee pocas ALUs de alta frecuencia, complementadas con sistemas complejos de predicción de saltos (*branch prediction*), ejecución fuera de orden y jerarquías densas de memoria caché (L1, L2, L3).

2.2 GPU (Graphics Processing Unit)

La GPU es un procesador masivamente paralelo diseñado originalmente para el renderizado gráfico, estructurado bajo el modelo SIMD (*Single Instruction, Multiple Data*) o SIMT (*Single Instruction, Multiple Threads*).

- **Cálculo Vectorial:** Diseñada para aplicar una misma instrucción sobre un conjunto unidimensional o bidimensional de datos de manera simultánea:

$$\mathbf{y} = f(\mathbf{x}) \quad \text{donde } \mathbf{x}, \mathbf{y} \in \mathbb{R}^n \quad (3)$$

- **Componentes:** Miles de núcleos simples (ALUs) optimizados para el *rendimiento total* (*throughput*) en lugar de la latencia de un único hilo.

2.3 TPU (Tensor Processing Unit)

La TPU prescinde de la flexibilidad general para optimizar de forma exclusiva el procesamiento matricial multidimensional (tensores).

- **Cálculo Tensorial:** Ejecuta operaciones directas sobre tensores de orden $n \geq 2$:

$$\mathcal{Y} = \mathcal{W} * \mathcal{X} + \mathcal{B} \quad (4)$$

- **Componentes:** Matriz masiva de ALUs interconectadas directamente sin registros intermedios, controlada por un procesador host (CPU) que gestiona el flujo de instrucciones de alto nivel y la alimentación de datos.

3 Similitudes y Dependencias Operativas

A pesar de las divergencias arquitectónicas, los tres procesadores comparten principios operativos fundamentales:

1. **Sustrato Matemático:** La ejecución interna se fundamenta en compuertas lógicas discretas agrupadas en ALUs que operan sobre tipos de datos numéricos comunes (punto flotante y enteros, como FP32, FP16, INT8, o formatos especializados como bfloat16).
2. **Jerarquía de Memoria:** Requieren un ancho de banda masivo para mitigar el cuello de botella de Von Neumann, implementando tecnologías como HBM (*High Bandwidth Memory*) en configuraciones avanzadas de GPUs y TPUs.
3. **Arquitectura de Coprocesamiento:** Ni la GPU ni la TPU funcionan de manera autónoma en un entorno de producción; ambas dependen de una CPU que actúa como nodo maestro (*host*) para la orquestación del sistema operativo, la gestión de entrada/salida (E/S) de datos y el despacho de kernels de cómputo (a través de CUDA o XLA).

4 Tabla Comparativa de Especificaciones Técnicas

Table 1: Matriz de diferenciación de arquitecturas de procesamiento.

Característica	CPU	GPU	TPU
Tipo de Cómputo	Escalar (x)	Vectorial ($\mathbf{x}$)	Tensorial ($\mathbf{X}$ o $\mathcal{X}$)
Granularidad del Núcleo	Pocos núcleos de alta complejidad y frecuencia.	Miles de núcleos de baja complejidad (SIMD).	Matriz sistólica masiva optimizada para operaciones MAC.
Flexibilidad Operativa	Máxima (Propósito general, condicionales complejos).	Moderada (Cálculo paralelo algorítmico, gráficos).	Mínima (Álgebra lineal restrictiva de redes neuronales).
Métrica de Optimización	Latencia mínima por instrucción.	Rendimiento (<i>Throughput</i>) masivo de datos por hilo.	Eficiencia energética y densidad de operaciones por ciclo.
Carga de Trabajo Ideal	Sistemas operativos, lógica web, algoritmos secuenciales.	Gráficos 3D, simulación HPC, preprocesamiento de datos.	Entrenamiento masivo e inferencia de LLMs y modelos profundos.

5 Conclusión

En resumen, la elección entre una CPU, GPU y TPU depende de qué tan especializada sea la tarea que se necesita resolver:

- **CPU:** Es el cerebro general que coordina todo el sistema. Es indispensable para que el equipo funcione y ejecute la lógica básica, pero no es la herramienta más rápida para calcular datos masivos.
- **GPU:** Es el trabajador multitarea. Destaca al realizar miles de operaciones matemáticas al mismo tiempo, lo que la hace ideal para procesar grandes volúmenes de información y entrenar modelos analíticos generales.
- **TPU:** Es el especialista extremo. Sacrifica la capacidad de hacer tareas comunes para enfocarse en una sola cosa: resolver las operaciones matemáticas que requieren las redes neuronales a una velocidad insuperable.

En conclusión, cada procesador tiene características únicas que ayudan a optimizar tareas específicas.